

ANÁLISE DE CRIMINALIDADE EM CIDADES DO INTERIOR DO ESTADO DE SÃO PAULO UTILIZANDO TÉCNICAS DE MINERAÇÃO DE DADOS

DISCIPLINA: MINERAÇÃO DE DADOS

RESUMO

A criminalidade representa um dos principais desafios enfrentados pelos órgãos públicos de segurança. O uso de técnicas de Mineração de Dados possibilita identificar padrões ocultos em grandes volumes de dados, auxiliando no processo de tomada de decisão. O presente trabalho tem como objetivo aplicar técnicas de agrupamento de dados e regras de associação em uma base real de criminalidade de cidades do interior do estado de São Paulo. Foram utilizadas técnicas de pré-processamento, normalização de dados, agrupamento utilizando o algoritmo K-Means, análise de componentes principais (PCA) e descoberta de padrões frequentes por meio do algoritmo Apriori. Os resultados obtidos permitiram identificar grupos de cidades com características criminais semelhantes e associações relevantes entre diferentes tipos de crimes.

1 – INTRODUÇÃO

A análise da criminalidade é um tema de grande relevância social, econômica e governamental. O aumento da disponibilidade de dados públicos permitiu o desenvolvimento de estudos mais avançados utilizando técnicas computacionais capazes de identificar padrões e tendências ocultas.

Nesse contexto, a Mineração de Dados surge como uma importante área da Ciência de Dados, possibilitando extrair conhecimento útil a partir de grandes bases de dados. Técnicas como agrupamento de dados e regras de associação têm sido amplamente utilizadas em diversas áreas, incluindo segurança pública, saúde, finanças e marketing.

O presente trabalho propõe a aplicação de técnicas de Mineração de Dados sobre uma base real de criminalidade de cidades do interior do estado de São Paulo. O objetivo principal consiste em identificar padrões criminais semelhantes entre municípios, bem como descobrir relações frequentes entre diferentes tipos de crimes.

2 – JUSTIFICATIVA

A segurança pública é um dos principais desafios enfrentados pelos governos e pela sociedade. A análise inteligente de dados criminais pode auxiliar órgãos públicos no planejamento estratégico e na distribuição mais eficiente de recursos.

A utilização de técnicas de Mineração de Dados torna possível identificar padrões ocultos, tendências e associações relevantes entre crimes, permitindo uma compreensão mais aprofundada da dinâmica criminal.

Além da relevância social, o estudo apresenta importância acadêmica por aplicar conceitos fundamentais da disciplina de Mineração de Dados em um problema real, envolvendo:

- pré-processamento de dados;
- normalização;
- agrupamento de dados;
- redução de dimensionalidade;
- descoberta de padrões frequentes;
- regras de associação.

Dessa forma, o trabalho contribui tanto para o desenvolvimento técnico quanto para a análise de um problema de grande impacto social.

3 – REVISÃO DA LITERATURA

3.1 – Mineração de Dados

A Mineração de Dados consiste no processo de descoberta de padrões relevantes em grandes conjuntos de dados utilizando técnicas estatísticas, matemáticas e computacionais.

O processo de mineração envolve etapas como:

- seleção dos dados;
- pré-processamento;
- transformação;
- mineração;
- interpretação dos resultados.

3.2 – Agrupamento de Dados (Clustering)

O agrupamento de dados é uma técnica de aprendizado não supervisionado cujo objetivo é dividir os dados em grupos semelhantes denominados clusters.

O algoritmo K-Means é um dos métodos mais populares devido à sua simplicidade e eficiência computacional. O algoritmo busca minimizar a distância entre os pontos e os centroides dos grupos.

A distância euclidiana utilizada pelo K-Means pode ser representada por:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

O algoritmo realiza sucessivas iterações até estabilizar os centroides dos clusters.

3.3 – Normalização dos Dados

A normalização é uma etapa fundamental em algoritmos baseados em distância, como o K-Means.

Neste trabalho foi utilizada a técnica StandardScaler, cuja fórmula é:

$$Z = \frac{x - \mu}{\sigma}$$

Onde:

- x representa o valor original;
- μ representa a média;
- σ representa o desvio padrão.

A normalização garante que variáveis com escalas elevadas não dominem o processo de agrupamento.

3.4 – Método do Cotovelo

O Método do Cotovelo é utilizado para auxiliar na definição do número ideal de clusters.

A técnica analisa a redução da inércia do modelo:

$$J = \sum_{i=1}^k \sum_{x_j \in C_i} ||x_j - c_i||^2$$

Onde:

- x_j representa os pontos;
- c_i representa o centroide do cluster.

O ponto em que a redução da inércia começa a desacelerar é considerado o número ideal de clusters.

3.5 – Silhouette Score

O Silhouette Score mede a qualidade dos agrupamentos gerados.

A métrica é definida por:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

Onde:

- $a(i)$ representa a distância média intra-cluster;
- $b(i)$ representa a distância média para o cluster vizinho mais próximo.

Valores próximos de 1 indicam melhor separação entre clusters.

3.6 – PCA – Principal Component Analysis

O PCA é uma técnica de redução de dimensionalidade utilizada para simplificar a visualização de dados multidimensionais.

A transformação pode ser representada por:

$$Z = XW$$

Onde:

- X representa os dados originais;
- W representa os componentes principais;
- Z representa os dados transformados.

3.7 – Regras de Associação

As regras de associação têm como objetivo identificar relações frequentes entre itens.

Neste trabalho foi utilizado o algoritmo Apriori. As principais métricas utilizadas foram:

- Suporte

$$Support(A) = \frac{\text{Número de transações contendo } A}{\text{Número total de transações}}$$

- Confiança (Confidence, em inglês)

$$Confidence(A \rightarrow B) = \frac{Support(A \cup B)}{Support(A)}$$

- Lift

$$Lift(A \rightarrow B) = \frac{Confidence(A \rightarrow B)}{Support(B)}$$

Valores de Lift maiores que 1 indicam associação positiva entre os itens.

4 – METODOLOGIA E RESULTADOS

4.1 – Base de Dados

Foi utilizada uma base de dados real contendo registros de criminalidade em cidades do interior do estado de São Paulo.

A base foi armazenada em um arquivo Excel denominado “arquivo.xlsx”.

Cada linha da base representa:

- uma cidade;
- um tipo de crime;
- ocorrências mensais.

Principais atributos:

- cidade;
- natureza;
- meses de janeiro a dezembro;
- total anual de ocorrências.

A base contém dados quantitativos e categóricos relacionados à criminalidade urbana.

4.2 – Pré-processamento dos Dados

Inicialmente foi criado o atributo “total_anual”, obtido pela soma das ocorrências mensais.

Posteriormente, algumas naturezas criminais foram removidas por apresentarem redundância ou excesso de especificidade.

As variáveis removidas foram:

- numero_de_vitimas_em_homicidio_doloso;
- numero_de_vitimas_em_homicidio_doloso_por_acidente_de_transito;
- numero_de_vitimas_em_latrocinio;
- total_de_estupro;
- total_de_roubos_outros.

Após essa etapa, os dados foram reorganizados utilizando Pivot Table, estruturando:

- linhas → cidades;
- colunas → tipos de crimes;
- valores → total anual.

Em seguida, os dados foram normalizados utilizando StandardScaler.

4.3 – Agrupamento de dados

Objetivo

O objetivo da análise de agrupamento foi identificar cidades com padrões semelhantes de criminalidade.

Algoritmo Utilizado

Foi utilizado o algoritmo K-Means.

A escolha ocorreu devido:

- à simplicidade;
- à eficiência computacional;
- à facilidade de interpretação dos resultados.

Definição do Número de Clusters

Foram testados valores de k entre 2 e 8.

Método do Cotovelo

O Método do Cotovelo foi utilizado para analisar a redução da inércia dos agrupamentos.




Figura 1 — Método do Cotovelo para definição do número ideal de clusters.

Fonte: Elaborado pelos autores (2026).

Silhouette Score

O índice Silhouette Score foi utilizado para validar a qualidade dos agrupamentos.

Os resultados indicaram que o valor $k = 3$ apresentou o melhor equilíbrio entre:

- coesão interna;
- separação entre clusters.

Resultado do Agrupamento

O algoritmo dividiu as cidades em três grupos principais:

- Cluster 0 → baixa criminalidade;
- Cluster 1 → média criminalidade;
- Cluster 2 → alta criminalidade.

Para facilitar a visualização, foi aplicada a técnica PCA.




Figura 2 — Visualização dos clusters utilizando PCA.

Fonte: Elaborado pelos autores (2026).

Avaliação dos Resultados

O valor final do Silhouette Score indicou separação razoável entre os clusters encontrados.

Além disso, as médias dos crimes por cluster permitiram identificar diferenças significativas entre os grupos.

4.4 – Análise de correlação

Foi gerado um Heatmap de Correlação para identificar relações lineares entre os diferentes tipos de crimes.




Figura 3 — Heatmap de correlação entre os tipos de crimes.

Fonte: Elaborado pelos autores (2026).

Os resultados demonstraram que determinados crimes apresentam forte correlação positiva, indicando possível coexistência nas mesmas cidades.

4.5 – Regras de associação

Objetivo

A análise de regras de associação teve como objetivo identificar quais tipos de crimes tendem a ocorrer simultaneamente nas cidades analisadas.

Pré-processamento

Os dados foram transformados em formato binário:

- 1 → houve ocorrência;
- 0 → não houve ocorrência.

Essa transformação foi necessária porque o algoritmo Apriori trabalha com dados transacionais binários.

Algoritmo Apriori

Foi utilizado o algoritmo Apriori da biblioteca mlxtend.

Parâmetros utilizados:

- suporte mínimo = 0,7;
- confiança mínima = 0,8;
- tamanho máximo dos itemsets = 3.

O suporte mínimo elevado foi escolhido para garantir padrões frequentes e representativos.

Regras Encontradas

As regras geradas apresentaram valores de Lift superiores a 1, indicando associações positivas entre diferentes tipos de crimes.

As principais regras demonstraram que determinados crimes tendem a ocorrer conjuntamente nas mesmas cidades.

5 – CONCLUSÃO

O presente trabalho demonstrou a aplicabilidade das técnicas de Mineração de Dados na análise de criminalidade urbana.

A utilização do algoritmo K-Means possibilitou identificar grupos distintos de cidades com padrões semelhantes de criminalidade. O uso do PCA facilitou a interpretação visual dos agrupamentos.

Além disso, o algoritmo Apriori permitiu identificar associações relevantes entre diferentes tipos de crimes, evidenciando padrões frequentes de ocorrência.

Os resultados obtidos demonstram que técnicas de Mineração de Dados podem auxiliar análises estratégicas em segurança pública, contribuindo para a tomada de decisão baseada em dados.

Como limitações do trabalho, destacam-se:

- ausência de variáveis socioeconômicas;

- utilização de apenas um período temporal (ano de 2025).

Como trabalhos futuros:

- utilização de variáveis socioeconômicas;
- utilização de um período temporal mais abrangente (incluindo outros anos, por exemplo).

REFERÊNCIAS

?????