

FATEC DE RIO CLARO
CURSO DE TECNOLOGIA EM INTELIGÊNCIA ARTIFICIAL

Felippe Sena Santuzzi

Paulo Augusto Coelho da Fonseca

**ANÁLISE DE CRIMINALIDADE EM CIDADES DO
INTERIOR DO ESTADO DE SÃO PAULO (REGIÃO DE
PIRACICABA) UTILIZANDO TÉCNICAS DE MINERAÇÃO
DE DADOS**

**Trabalho apresentado à disciplina de Mineração de Dados do curso
de Tecnologia em Inteligência Artificial, da Fatec de Rio Claro.**

Professora Angela Rosa Locateli de Godoy

Rio Claro – SP

2026

RESUMO

A criminalidade representa um dos principais desafios enfrentados pelos órgãos públicos de segurança. O uso de técnicas de Mineração de Dados possibilita identificar padrões ocultos em grandes volumes de dados, auxiliando no processo de tomada de decisão. O presente trabalho tem como objetivo aplicar técnicas de agrupamento de dados e regras de associação em uma base real de criminalidade relacionada a cinquenta e duas cidades do interior do estado de São Paulo – região de Piracicaba – a saber: Aguai, Águas da Prata, Águas de São Pedro, Americana, Analândia, Araras, Artur Nogueira, Brotas, Caconde, Capivari, Casa Branca, Charqueada, Conchal, Cordeirópolis, Corumbataí, Cosmópolis, Divinolândia, Elias Fausto, Engenheiro Coelho, Espírito Santo do Pinhal, Hortolândia, Ipeúna, Iracemápolis, Itirapina, Itobi, Leme, Limeira, Mococa, Mombuca, Monte Mor, Nova Odessa, Piracicaba, Pirassununga, Rafard, Rio Claro, Rio das Pedras, Saltinho, Santa Bárbara d'Oeste, Santa Cruz da Conceição, Santa Cruz das Palmeiras, Santa Gertrudes, Santa Maria da Serra, Santo Antônio do Jardim, São João da Boa Vista, São José do Rio Pardo, São Pedro, São Sebastião da Gramma, Sumaré, Tambaú, Tapiratiba, Torrinha, Vargem Grande do Sul.

Foram utilizadas técnicas de pré-processamento, normalização de dados, agrupamento utilizando o algoritmo K-Means, análise de componentes principais (PCA) e descoberta de padrões frequentes por meio do algoritmo Apriori. Os resultados obtidos permitiram identificar grupos de cidades com características criminais semelhantes e associações relevantes entre diferentes tipos de crimes.

1 – INTRODUÇÃO

A análise da criminalidade é um tema de grande relevância social, econômica e governamental. O aumento da disponibilidade de dados públicos permitiu o desenvolvimento de estudos mais avançados utilizando técnicas computacionais capazes de identificar padrões e tendências ocultas.

Nesse contexto, a Mineração de Dados surge como uma importante área da Ciência de Dados, possibilitando extrair conhecimento útil a partir de grandes bases de dados. Técnicas como agrupamento de dados e regras de associação têm sido amplamente utilizadas em diversas áreas, incluindo segurança pública, saúde, finanças e marketing.

O presente trabalho propõe a aplicação de técnicas de Mineração de Dados sobre uma base real de criminalidade de cidades do interior do estado de São Paulo (região de Piracicaba). O objetivo principal consiste em identificar padrões criminais semelhantes entre municípios, bem como descobrir relações frequentes entre diferentes tipos de crimes.

2 – JUSTIFICATIVA

A segurança pública é um dos principais desafios enfrentados pelos governos e pela sociedade. A análise inteligente de dados criminais pode auxiliar órgãos públicos no planejamento estratégico e na distribuição mais eficiente de recursos.

A utilização de técnicas de Mineração de Dados torna possível identificar padrões ocultos, tendências e associações relevantes entre crimes, permitindo uma compreensão mais aprofundada da dinâmica criminal.

Além da relevância social, o estudo apresenta importância acadêmica por aplicar conceitos fundamentais da disciplina de Mineração de Dados em um problema real, envolvendo:

- pré-processamento de dados;
- normalização;
- agrupamento de dados;
- redução de dimensionalidade;
- descoberta de padrões frequentes;
- regras de associação.

Dessa forma, o trabalho contribui tanto para o desenvolvimento técnico quanto para a análise de um problema de grande impacto social.

3 – REVISÃO TEÓRICA

3.1 – Mineração de Dados

A Mineração de Dados consiste no processo de descoberta de padrões relevantes em grandes conjuntos de dados utilizando técnicas estatísticas, matemáticas e computacionais.

O processo de mineração envolve etapas como:

- seleção dos dados;
- pré-processamento;
- transformação;
- mineração;
- interpretação dos resultados.

3.2 – Agrupamento de Dados (Clustering)

O agrupamento de dados é uma técnica de aprendizado não supervisionado cujo objetivo é dividir os dados em grupos semelhantes denominados clusters.

O algoritmo K-Means é um dos métodos mais populares devido à sua simplicidade e eficiência computacional. O algoritmo busca minimizar a distância entre os pontos e os centroides dos grupos.

A distância euclidiana utilizada pelo K-Means pode ser representada por:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

O algoritmo realiza sucessivas iterações até estabilizar os centroides dos clusters.

3.3 – Normalização dos Dados

A normalização é uma etapa fundamental em algoritmos baseados em distância, como o K-Means.

Neste trabalho foi utilizada a técnica StandardScaler, cuja fórmula é:

$$Z = \frac{x - \mu}{\sigma}$$

Onde:

- x representa o valor original;
- μ representa a média;
- σ representa o desvio padrão.

A normalização garante que variáveis com escalas elevadas não dominem o processo de agrupamento.

3.4 – Método do Cotovelo

O Método do Cotovelo é utilizado para auxiliar na definição do número ideal de clusters.

A técnica analisa a redução da inércia do modelo:

$$J = \sum_{i=1}^k \sum_{x_j \in C_i} ||x_j - c_i||^2$$

Onde:

- x_j representa os pontos;
- c_i representa o centroide do cluster.

O ponto em que a redução da inércia começa a desacelerar é considerado o número ideal de clusters.

3.5 – Silhouette Score

O Silhouette Score mede a qualidade dos agrupamentos gerados.

A métrica é definida por:

$$s(i) = \frac{b(i)-a(i)}{\max(a(i),b(i))}$$

Onde:

- $a(i)$ representa a distância média intra-cluster;
- $b(i)$ representa a distância média para o cluster vizinho mais próximo.

Valores próximos de 1 indicam melhor separação entre clusters.

3.6 – PCA – Principal Component Analysis

O PCA é uma técnica de redução de dimensionalidade utilizada para simplificar a visualização de dados multidimensionais.

A transformação pode ser representada por:

$$Z = XW$$

Onde:

- X representa os dados originais;
- W representa os componentes principais;
- Z representa os dados transformados.

3.7 – Regras de Associação

As regras de associação têm como objetivo identificar relações frequentes entre itens.

Neste trabalho foi utilizado o algoritmo Apriori. As principais métricas utilizadas foram:

- Suporte

$$Support(A) = \frac{\text{Número de transações contendo } A}{\text{Número total de transações}}$$

- Confiança (Confidence, em inglês)

$$Confidence(A \rightarrow B) = \frac{Support(A \cup B)}{Support(A)}$$

- Lift

$$Lift(A \rightarrow B) = \frac{Confidence(A \rightarrow B)}{Support(B)}$$

Valores de Lift maiores que 1 indicam associação positiva entre os itens.

4 – METODOLOGIA E RESULTADOS

4.1 – Base de Dados

Foi utilizada uma base de dados real contendo registros de criminalidade em cidades do interior do estado de São Paulo – região de Piracicaba.

A base foi armazenada em um arquivo Excel denominado “arquivo.xlsx”.

Cada linha da base representa:

- uma cidade;
- um tipo de crime;
- ocorrências mensais.

Principais atributos:

- cidade;
- natureza;
- meses de janeiro a dezembro;
- total anual de ocorrências.

A base contém dados quantitativos e categóricos relacionados à criminalidade urbana.

Foi incluída a coluna “ordem_id” e cada um dos meses foram transformados em um número inteiro. Além disso, todas as letras foram minúsculas, todos os espaços foram substituídos por underline ou sublinhado (_) e toda a acentuação gráfica foi extraída.

4.2 – Pré-processamento dos Dados

Inicialmente foi criado o atributo “total_anual”, obtido pela soma das ocorrências mensais.

Posteriormente, algumas naturezas criminais foram removidas por apresentarem redundância ou excesso de especificidade.

As variáveis removidas foram:

- numero_de_vitimas_em_homicidio_doloso;
- numero_de_vitimas_em_homicidio_doloso_por_acidente_de_transito;
- numero_de_vitimas_em_latrocinio;
- total_de_estupro;
- total_de_roubos_outros.

Após essa etapa, os dados foram reorganizados utilizando Pivot Table, estruturando:

- linhas → cidades;
- colunas → tipos de crimes;
- valores → total anual.

Em seguida, os dados foram normalizados utilizando StandardScaler.

4.3 – Agrupamento de dados

Objetivo

O objetivo da análise de agrupamento foi identificar cidades com padrões semelhantes de criminalidade.

Algoritmo Utilizado

Foi utilizado o algoritmo K-Means.

A escolha ocorreu devido:

- à simplicidade;
- à eficiência computacional;
- à facilidade de interpretação dos resultados.

Definição do Número de Clusters

Foram testados valores de k entre 2 e 8.

Método do Cotovelo

O Método do Cotovelo foi utilizado para analisar a redução da inércia dos agrupamentos.




Figura 1 – Método do Cotovelo para definição do número ideal de clusters.

Fonte: Elaborado pelos autores (2026).

Silhouette Score

O índice Silhouette Score foi utilizado para validar a qualidade dos agrupamentos.

Os resultados indicaram que o valor $k = 3$ apresentou o melhor equilíbrio entre:

- coesão interna;
- separação entre clusters.

Resultado do Agrupamento

O algoritmo dividiu as cidades em três grupos principais:

- Cluster 0 → baixa criminalidade;
- Cluster 1 → média criminalidade;
- Cluster 2 → alta criminalidade.

Para facilitar a visualização, foi aplicada a técnica PCA.




Figura 2 – Visualização dos clusters utilizando PCA.

Fonte: Elaborado pelos autores (2026).

Avaliação dos Resultados

O valor final do Silhouette Score indicou separação razoável entre os clusters encontrados.

Além disso, as médias dos crimes por cluster permitiram identificar diferenças significativas entre os grupos.

4.4 – Análise de correlação

Foi gerado um Heatmap de Correlação para identificar relações lineares entre os diferentes tipos de crimes.




Figura 3 – Heatmap de correlação entre os tipos de crimes.

Fonte: Elaborado pelos autores (2026).

Os resultados demonstraram que determinados crimes apresentam forte correlação positiva, indicando possível coexistência nas mesmas cidades.

4.5 – Regras de associação

Objetivo

A análise de regras de associação teve como objetivo identificar quais tipos de crimes tendem a ocorrer simultaneamente nas cidades analisadas.

Pré-processamento

Os dados foram transformados em formato binário:

- 1 → houve ocorrência;
- 0 → não houve ocorrência.

Essa transformação foi necessária porque o algoritmo Apriori trabalha com dados transacionais binários.

Algoritmo Apriori

Foi utilizado o algoritmo Apriori da biblioteca mlxtend.

Parâmetros utilizados:

- suporte mínimo = 0,7;
- confiança mínima = 0,8;
- tamanho máximo dos itemsets = 3.

O suporte mínimo elevado foi escolhido para garantir padrões frequentes e representativos.

Regras Encontradas

As regras geradas apresentaram valores de Lift superiores a 1, indicando associações positivas entre diferentes tipos de crimes.

As principais regras demonstraram que determinados crimes tendem a ocorrer conjuntamente nas mesmas cidades.

4.6 – Análise de Outliers: Rio Claro

Objetivo

Durante a visualização dos clusters utilizando a técnica de Análise de Componentes Principais (PCA), observou-se que o município de Rio Claro apresentou comportamento distinto dentro do Cluster 1 (alta criminalidade), sugerindo a presença de possíveis outliers.

O objetivo desta etapa foi identificar quais tipos de crimes apresentavam valores significativamente acima da média geral das cidades e da média do próprio cluster ao qual Rio Claro pertence.

Metodologia

Para a análise de outliers foi utilizada a técnica de Z-score, aplicada sobre os dados previamente normalizados por meio do método StandardScaler.

Novamente, o Z-score é definido por:

$$Z = \frac{x - \mu}{\sigma}$$

Onde:

- x representa o valor observado;
- μ representa a média dos valores;
- σ representa o desvio padrão.

Essa métrica indica quantos desvios padrão um valor está distante da média. Neste contexto, foram adotados os seguintes critérios:

- $Z > 2 \rightarrow$ possível outlier moderado;
- $Z > 3 \rightarrow$ outlier severo.

Inicialmente, foram calculados os Z-scores de Rio Claro para cada tipo de crime. Em seguida, os valores foram comparados com a média do cluster ao qual o município pertence, permitindo uma análise relativa mais precisa.

Resultados

Os resultados indicaram que o município de Rio Claro apresenta valores significativamente superiores à média em determinados tipos de crimes, mesmo quando comparado exclusivamente às cidades do mesmo cluster.

A análise dos Z-scores permitiu identificar quais crimes se destacam de forma mais acentuada em relação ao padrão geral das demais cidades.

Além disso, a comparação entre Rio Claro e a média do Cluster 1 evidenciou diferenças relevantes na magnitude de determinados tipos de ocorrência criminal.

Análise Comparativa com o Cluster

A comparação entre os valores de Rio Claro e a média do cluster permitiu observar o comportamento relativo do município dentro do seu grupo de similaridade.

Foram calculadas três medidas principais:

- valor absoluto de Rio Claro;
- média do cluster;
- razão entre Rio Claro e a média do cluster.

Essa análise possibilitou identificar quais crimes apresentam maior discrepância proporcional em relação ao comportamento médio do grupo.

Visualizações Geradas

Foram construídos dois gráficos para auxiliar na interpretação dos resultados:




Figura 4 – Comparação entre Rio Claro e a média do Cluster 1.

Fonte: Elaborado pelos autores (2026).

Gráfico de barras comparando os principais tipos de crimes entre o município e a média do seu cluster.




Figura 5 – Z-score dos crimes em Rio Claro.

Fonte: Elaborado pelos autores (2026).

Gráfico horizontal destacando os desvios padrão de cada tipo de crime, com marcação de limiar para identificação de outliers ($Z > 2$).

Conclusão da Análise de Outliers

A análise de outliers demonstrou que, embora Rio Claro pertença a um cluster de alta criminalidade, alguns tipos de crimes apresentam valores significativamente acima do padrão do grupo.

Isso indica que o município possui características criminais específicas que não são totalmente capturadas apenas pela análise de agrupamento, reforçando a importância de análises complementares como o Z-score para uma compreensão mais detalhada dos dados.

5 – CONCLUSÃO

O presente trabalho demonstrou a importância das técnicas de Mineração de Dados na análise da criminalidade em cidades do interior do estado de São Paulo – região de Piracicaba. Por meio do uso de técnicas como normalização, agrupamento de dados, PCA e regras de associação, foi possível identificar padrões relevantes nos dados criminais analisados.

O algoritmo K-Means permitiu separar as cidades em grupos com características semelhantes de criminalidade, enquanto o PCA auxiliou na visualização desses agrupamentos. Além disso, a análise de correlação e as regras de associação mostraram relações importantes entre diferentes tipos de crimes.

A cidade de Rio Claro apresentou destaque durante as análises, principalmente na etapa de detecção de outliers. Mesmo pertencendo a um cluster de alta criminalidade, alguns tipos de crimes apresentaram valores acima da média do próprio grupo, indicando características específicas do município.

Os resultados mostram que a Mineração de Dados pode auxiliar na compreensão dos padrões criminais e contribuir para análises relacionadas à segurança pública.

Como trabalhos futuros, recomenda-se a utilização de mais anos de dados e a inclusão de variáveis socioeconômicas.

REFERÊNCIAS

GODOY, Angela Rosa Locateli de. Fatec de Rio Claro – SP (material de estudo), 2026

GODOY, Angela Rosa Locateli de. “Aplicação de Algoritmos de Aprendizado de Máquina à Análise de Concentrações de MP2,5 em cidades do estado de São Paulo”

Secretaria da Segurança Pública do Estado de São Paulo. Dados mensais. Encontrado em <https://www.ssp.sp.gov.br/estatistica/dados-mensais>